پروژه نهایی

درس مبانی بینایی کامپیوتر

روجا آقاجانی 810101380

مانا مرادی 810101517

مقدمه

تصاویر قدیمی ممکن است در اثر گذشت زمان دچار محوشدگی، کاهش کنتراست، تغییر رنگ، نویز، گردوغبار، خط و خش، ترک یا از دست رفتن بخشی از جزئیات شوند. بازسازی دستی این تصاویر زمان‌بر است و کیفیت آن به مهارت کاربر وابسته است. در بینایی کامپیوتر می‌توان با استفاده از مدل‌های یادگیری عمیق، نگاشتی از تصویر آسیب‌دیده به نسخه سالم‌تر و نزدیک‌تر به تصویر اصلی آموخت. در این پروژه مسئله به صورت یادگیری نظارت‌شده تعریف شده است؛ به این معنی که برای هر ورودی آسیب‌دیده، یک تصویر سالم متناظر به عنوان هدف در دسترس است.

اهداف اصلی این پروژه عبارت‌اند از:

- آماده‌سازی جفت تصاویر آسیب‌دیده و سالم و ساخت DataLoaderهای مناسب.
- انتخاب و پیاده‌سازی یک معماری مناسب برای بازسازی تصویر با خروجی هم‌اندازه ورودی.
- آموزش مدل و ثبت روند Train Loss و Validation Loss.
- ارزیابی کمی مدل روی مجموعه تست با معیارهای PSNR و SSIM و معیارهای تکمیلی MSE و MAE.
- ارزیابی کیفی خروجی‌ها با نمایش حداقل پنج نمونه شامل ورودی آسیب‌دیده، تصویر مرجع و خروجی بازسازی‌شده.

۲.مجموعه‌داده

مجموعه‌داده استفاده‌شده با نام joshuachin/openphoto-restore-dataset از Hugging Face بارگذاری شد. هر نمونه دارای دو فیلد تصویری میباشد: damaged_image که ورودی آسیب‌دیده مدل را تشکیل می‌دهد و pristine_image که تصویر سالم متناظر و Ground Truth است. مجموعه‌داده اصلی شامل ۴۵۰۰ نمونه آموزش و ۵۰۰ نمونه تست است. در این پروژه، ۱۰ درصد از بخش آموزش برای اعتبارسنجی جدا شد؛ بنابراین ۴۰۵۰ نمونه برای آموزش، ۴۵۰ نمونه برای اعتبارسنجی و ۵۰۰ نمونه برای آزمون نهایی استفاده شد.

۳. پیش‌پردازش و آماده‌سازی داده‌ها

تصاویر باید خوانده شوند، ابعاد آن‌ها یکسان شود، مقادیر پیکسل نرمال‌سازی شود، داده‌ها به سه بخش آموزش، اعتبارسنجی و تست تقسیم شوند و DataLoader مناسب ساخته شود. این مراحل در کد به صورت زیر انجام شدند.

۳-۱. خواندن جفت تصاویر و تبدیل به RGB

در کلاس PhotoRestoreDataset، برای هر شاخص، تصویر آسیب‌دیده و تصویر سالم متناظر با کلیدهای واقعی مجموعه‌داده خوانده می‌شوند. سپس هر دو تصویر به RGB تبدیل می‌شوند تا ورودی و هدف دارای سه کانال یکسان باشند. این تبدیل مانع ایجاد ناسازگاری در تعداد کانال‌ها می‌شود.

```
damaged_img = item["damaged_image"].convert("RGB")
pristine_img = item["pristine_image"].convert("RGB")
```

۳-۲. یکسان‌سازی اندازه و نرمال‌سازی

تمام تصاویر به ابعاد ۲۵۶×۲۵۶ تغییر اندازه داده شدند. این اندازه در صورت پروژه نیز به عنوان یکی از اندازه‌های پیشنهادی برای کاهش هزینه آموزش ذکر شده است. تبدیل ToTensor علاوه بر تبدیل ساختار تصویر از H×W×C به C×H×W، مقادیر پیکسل را از بازه صحیح ۰ تا ۲۵۵ به بازه اعشاری ۰ تا ۱ نگاشت می‌کند.

```
transform = transforms.Compose([
    transforms.Resize((256, 256), antialias=True),
    transforms.ToTensor(),
])
```

۳-۳. تقسیم داده و ساخت DataLoader

بخش train اصلی با استفاده از seed برابر ۴۲ و نسبت ۹۰/۱۰ به آموزش و اعتبارسنجی تقسیم شد. ثابت بودن seed باعث می‌شود انتخاب نمونه‌های آموزش و اعتبارسنجی در اجراهای مختلف تا حد زیادی ثابت بماند. در DataLoader آموزش، shuffle فعال شد تا ترتیب نمونه‌ها در هر دوره تغییر کند؛ در اعتبارسنجی و تست shuffle غیرفعال است. اندازه دسته آموزش و اعتبارسنجی ۱۶ و اندازه دسته تست ۱ انتخاب شد تا معیارهای هر تصویر به صورت مستقل محاسبه شوند.

۳-۴. کنترل صحت داده‌ها

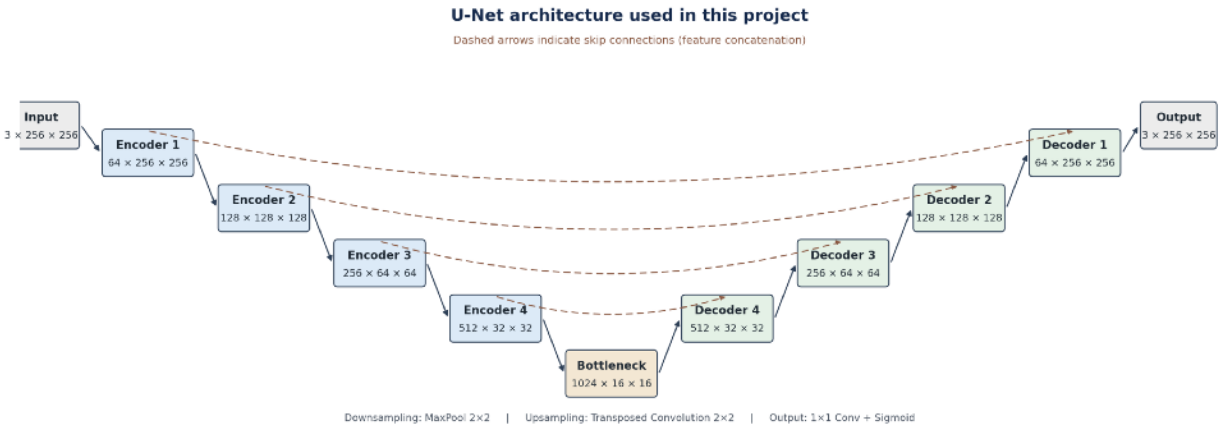
پیش از شروع آموزش، یک دسته از داده خوانده شد و با assert بررسی شد که ابعاد ورودی و هدف برابر [Batch, 3, 256, 256] باشد و همه مقادیر در بازه صفر تا یک قرار داشته باشند. این کنترل از آغاز آموزش طولانی با داده یا شکل ورودی اشتباه جلوگیری می‌کند.

۴. انتخاب و پیاده‌سازی معماری

۴-۱. دلیل انتخاب U-Net

مدل انتخابی U-Net است. این معماری از نظر کلی یک ساختار Encoder-Decoder دارد، اما برخلاف یک Autoencoder ساده، بین سطوح متناظر رمزگذار و رمزگشا اتصال میان‌بُر ایجاد می‌کند. در بازسازی تصویر، اطلاعات مکانی دقیق، لبه‌ها و بافت‌های محلی اهمیت زیادی دارند. اگر تمام اطلاعات فقط از یک گلوگاه فشرده عبور کنند، بخشی از جزئیات ریز از دست می‌رود. اتصال‌های میان‌بُر ویژگی‌های سطح پایین و با وضوح بالا را مستقیماً به رمزگشا منتقل می‌کنند و به حفظ ساختار تصویر کمک می‌کنند.

در مقایسه، یک Autoencoder ساده ممکن است به دلیل فشرده‌سازی شدید، خروجی‌های نرم و کم‌جزئیات تولید کند. VAE به دلیل گلوگاه احتمالاتی بیشتر برای مدل‌سازی توزیع و تولید داده جدید مناسب است و الزام بازسازی دقیق پیکسل‌به‌پیکسل را با یک مؤلفه تصادفی همراه می‌کند. GAN می‌تواند خروجی‌های شارپ ایجاد کند، اما آموزش آن پیچیده‌تر و ناپایدارتر است و امکان تولید جزئیات ظاهراً واقعی ولی غیرمنطبق با تصویر اصلی وجود دارد. برای این پروژه، U-Net تعادل مناسبی میان پایداری آموزش، حفظ ساختار و پیچیدگی پیاده‌سازی فراهم می‌کند.



شکل ۲ - ساختار U-Net پیاده‌سازی‌شده و اتصال‌های میان‌بُر میان رمزگذار و رمزگشا

۴-۲. ساختار کلی مدل

ورودی مدل یک تصویر RGB با ابعاد ۲۵۶×۲۵۶×۳ است. مسیر رمزگذار چهار بلوک DoubleConv با تعداد کانال‌های ۶۴، ۱۲۸، ۲۵۶ و ۵۱۲ دارد. پس از هر بلوک، MaxPool با کرنل ۲×۲ ابعاد مکانی را نصف می‌کند. در پایین‌ترین سطح، گلوگاه دارای ۱۰۲۴ کانال و ابعاد ۱۶×۱۶ است. مسیر رمزگشا با ConvTranspose2d ابعاد را دو برابر می‌کند، ویژگی‌های متناظر رمزگذار را به صورت کانالی الحاق می‌کند و سپس یک DoubleConv اعمال می‌شود. در پایان، کانولوشن ۱×۱ تعداد کانال‌ها را به ۳ کاهش می‌دهد و Sigmoid خروجی را در بازه صفر تا یک محدود می‌کند.

عملیات اصلی	ابعاد مکانی	تعداد کانال	مرحله
تصویر RGB آسیب‌دیده	۲۵۶×۲۵۶	۳	ورودی

مرحله	تعداد کانال	ابعاد مکانی	عملیات اصلی
Encoder 1	۶۴	۲۵۶×۲۵۶	DoubleConv
Encoder 2	۱۲۸	۱۲۸×۱۲۸	MaxPool + DoubleConv
Encoder 3	۲۵۶	۶۴×۶۴	MaxPool + DoubleConv
Encoder 4	۵۱۲	۳۲×۳۲	MaxPool + DoubleConv
Bottleneck	۱۰۲۴	۱۶×۱۶	DoubleConv
Decoder 4	۵۱۲	۳۲×۳۲	UpConv + Concat + DoubleConv
Decoder 3	۲۵۶	۶۴×۶۴	UpConv + Concat + DoubleConv
Decoder 2	۱۲۸	۱۲۸×۱۲۸	UpConv + Concat + DoubleConv
Decoder 1	۶۴	۲۵۶×۲۵۶	UpConv + Concat + DoubleConv
خروجی	۳	۲۵۶×۲۵۶	Conv 1×1 + Sigmoid

جدول ۲ - ابعاد ویژگی‌ها در مراحل مختلف شبکه

۳-۴. مزایا و محدودیت‌های معماری برای این مسئله

مزایای اصلی:

- حفظ بهتر لبه‌ها و ساختار مکانی به دلیل Skip Connectionها.
- پایداری بیشتر آموزش نسبت به مدل‌های رقابتی مانند GAN.
- تولید خروجی هم‌اندازه ورودی و مناسب بودن برای نگاشت تصویر به تصویر.
- امکان یادگیری همزمان حذف نویز، کاهش آثار خراش، اصلاح روشنایی و بازیابی بخشی از رنگ.

محدودیت‌های اصلی:

- اتصال‌های میان‌بُر ممکن است بخشی از الگوهای آسیب مانند خراش‌های قوی را نیز به رمزگشا منتقل کنند.
- استفاده تنها از L1 می‌تواند به خروجی‌های نرم یا رنگ‌های محافظه‌کارانه و کم‌اشباع منجر شود.
- مدل نسبتاً بزرگ است و در ابعاد ۲۵۶×۲۵۶ به حافظه و زمان آموزش قابل توجه نیاز دارد.

۵. آموزش مدل

۵-۱. تابع هزینه

تابع هزینه L1 یا میانگین قدر مطلق خطا برای آموزش استفاده شد. این تابع فاصله مطلق میان پیکسل‌های خروجی و تصویر مرجع را محاسبه می‌کند. در مقایسه با MSE، L1 نسبت به خطاهای بزرگ حساسیت مربعی ندارد و معمولاً در مسائل بازسازی به کاهش هموارشدگی بیش از حد کمک می‌کند.

$$L1 = (1/N) \Sigma |\hat{y}_i - y_i|$$

در رابطه فوق، $\hat{y}$ خروجی مدل، y تصویر سالم مرجع و N تعداد کل مقادیر پیکسل است.

۵-۲. بهینه‌ساز و تنظیمات آموزش

برای به‌روزرسانی وزن‌ها از Adam استفاده شد. Adam با نگهداری میانگین‌های متحرک گرادیان و مربع گرادیان، نرخ یادگیری مؤثر هر پارامتر را تطبیق می‌دهد و برای آموزش شبکه‌های کانولوشنی انتخاب مناسبی است. تنظیمات نهایی مطابق فایل run_config.json در جدول زیر آمده است.

پارامتر	مقدار
معماری	U-Net
تابع هزینه	L1Loss
بهینه‌ساز	Adam
نرخ یادگیری اولیه	0.0001
Weight Decay	0.0
Batch Size	16
تعداد Epoch	15
اندازه ورودی	256×256 RGB
نسبت Validation	10% از train اصلی
Seed	42
Mixed Precision	فعال روی CUDA
Scheduler	ReduceLROnPlateau، factor=0.5، patience=2
Early Stopping	patience=5

جدول ۳ - تنظیمات آموزش مدل

۵-۳. سخت‌افزار مورد استفاده

آموزش در محیط Google Colab و با استفاده از CUDA GPU انجام شد.

```
Using compute device: cuda
GPU: Tesla T4
```

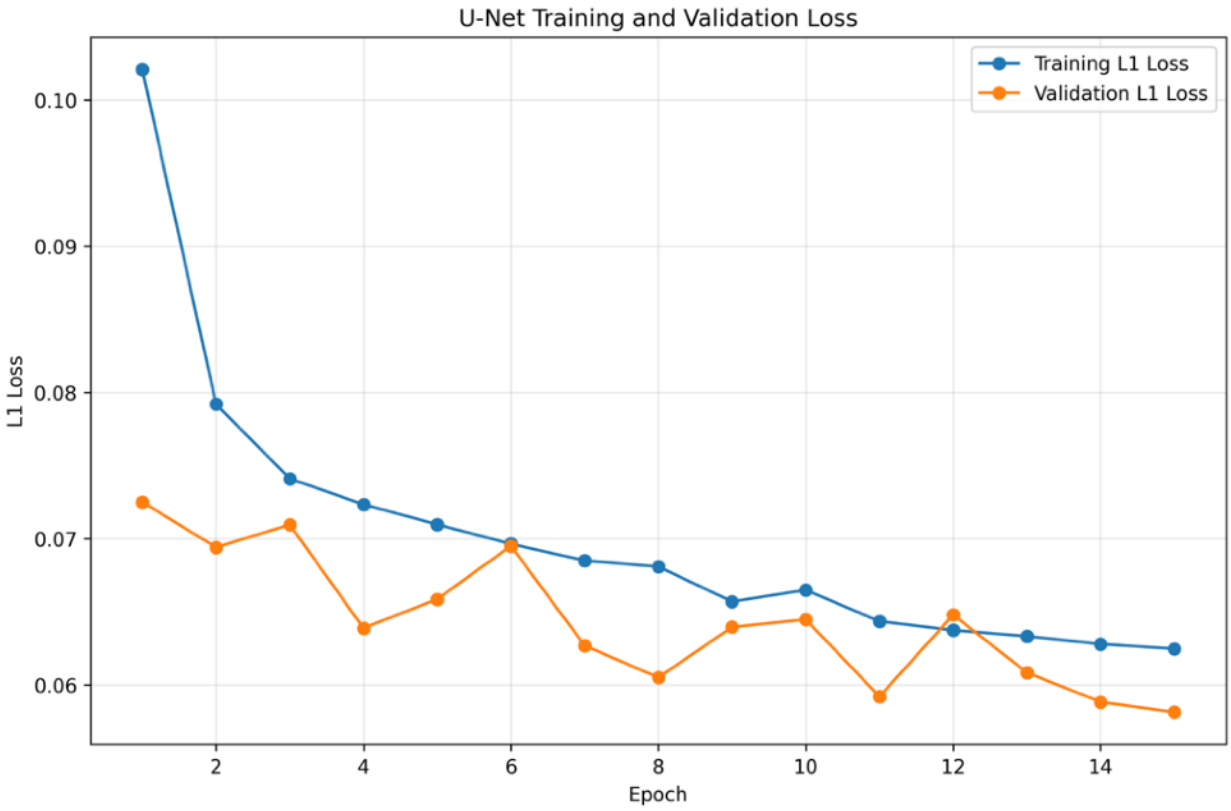
۵-۴. ذخیره بهترین مدل و کنترل روند آموزش

پس از هر دوره، L1 میانگین مجموعه اعتبارسنجی محاسبه شد. اگر این مقدار از بهترین مقدار قبلی کمتر بود، وزن‌های مدل همراه با شماره دوره، وضعیت optimizer، بهترین Validation Loss و تنظیمات اجرا ذخیره شدند. بنابراین ارزیابی نهایی بر مبنای بهترین checkpoint انجام شد و نه صرفاً آخرین وزن‌های آموزش. Scheduler برای کاهش نرخ یادگیری در زمان توقف بهبود اعتبارسنجی و Early Stopping برای توقف در صورت عدم بهبود پنج‌دوره‌ای در کد وجود داشتند. در اجرای حاضر، بهبودهای دوره‌ای ادامه یافت و آموزش تا دوره ۱۵ کامل شد؛ نرخ یادگیری نیز در تمام دوره‌ها برابر ۱۰^{-4} باقی ماند.

```
criterion = nn.L1Loss()
optimizer = optim.Adam(model.parameters(), lr=1e-4)

if val_loss < best_val_loss:
   torch.save(checkpoint, BEST_MODEL_PATH)
```

۶. نمودار Train Loss و Validation Loss



شکل ۳ - تغییرات **L1 Loss** آموزش و اعتبارسنجی طی ۱۵ دوره

۶-۱. تحلیل نمودار

Train Loss از ۰,۱۰۲۱۰ در دوره اول به ۰,۰۶۲۴۸ در دوره پانزدهم کاهش یافته است. بیشترین کاهش در ابتدای آموزش رخ داده و سپس شیب کاهش کمتر شده است که نشان می‌دهد مدل ابتدا الگوهای عمومی تخریب و ساختار تصویر را سریع یاد گرفته و در دوره‌های بعد به اصلاح تدریجی جزئیات پرداخته است. Validation Loss نیز از ۰,۰۷۲۵۲ به ۰,۰۵۸۱۵ رسیده و با وجود نوسان‌های طبیعی، روند کلی آن نزولی است.

در نمودار، Validation Loss در بسیاری از دوره‌ها از Train Loss کمتر است. این وضعیت به‌تنهایی نشانه خطا نیست؛ زیرا Train Loss میانگین خطا در طول تمام به‌روزرسانی‌های همان دوره است، در حالی که Validation Loss پس از پایان دوره و با وزن‌های به‌روز محاسبه می‌شود. همچنین ممکن است زیرمجموعه اعتبارسنجی اندکی ساده‌تر از داده‌های آموزش باشد. از آنجا که در انتهای آموزش Train Loss کاهش می‌یابد و Validation Loss نیز افزایش پایدار و واگرا نشان نمی‌دهد، نشانه روشنی از بیش‌برازش شدید مشاهده نمی‌شود.

Epoch	Train L1	Validation L1

1	0.102097	0.072516
2	0.079201	0.069416
4	0.072351	0.063892
8	0.068096	0.060515
11	0.064357	0.059213
15	0.062480	0.058148

جدول ۴ - مقادیر منتخب تابع هزینه در طول آموزش

۷. ارزیابی مدل

پس از پایان آموزش، بهترین checkpoint روی کل مجموعه تست شامل ۵۰۰ تصویر ارزیابی شد. هیچ نمونه‌ای از مجموعه تست در آموزش، تنظیم وزن‌ها یا انتخاب checkpoint استفاده نشد. معیارهای اصلی PSNR و SSIM مطابق صورت پروژه محاسبه شدند و MSE و MAE نیز به عنوان معیارهای تکمیلی گزارش شدند.

۷-۱. معیار MSE

MSE میانگین مربع اختلاف پیکسل‌های خروجی و تصویر مرجع است. مقدار کمتر نشان‌دهنده خطای پیکسلی کمتر است. به دلیل مربع شدن خطا، اختلاف‌های بزرگ سهم بیشتری در مقدار نهایی دارند.

$$\mathbf{MSE = (1/N)\ \Sigma\ (\hat{y}_i - y_i)^2}$$

۷-۲. معیار MAE

MAE میانگین قدر مطلق اختلاف پیکسل‌هاست و از نظر فرم با L1 مشابه است. مقدار کمتر بهتر است. تفاوت در این پروژه این است که L1 در فرایند آموزش برای بهینه‌سازی وزن‌ها به کار رفته، در حالی که MAE پس از آموزش به عنوان معیار گزارش عملکرد روی مجموعه تست محاسبه شده است.

$$\mathbf{MAE = (1/N)\ \Sigma\ |\hat{y}_i - y_i|}$$

۷-۳. معیار PSNR

PSNR نسبت بیشینه سیگنال به نویز را بر حسب دسی‌بل بیان می‌کند و بر پایه MSE محاسبه می‌شود. در این پروژه مقادیر تصاویر در بازه صفر تا یک هستند، بنابراین MAX_I برابر ۱ است. مقدار بیشتر PSNR نشان‌دهنده شباهت پیکسلی بیشتر خروجی به تصویر مرجع است.

$$PSNR = 10 \log_{10}(MAX_I^2 / MSE), \quad MAX_I = 1$$

۷-۴. معیار SSIM

SSIM شباهت ساختاری را با در نظر گرفتن روشنایی، کنتراست و ساختار محلی اندازه‌گیری می‌کند. این معیار نسبت به مقایسه صرف پیکسل‌به‌پیکسل به ادراک بصری نزدیک‌تر است. مقدار آن معمولاً در بازه صفر تا یک قرار دارد و مقدار نزدیک‌تر به یک نشان‌دهنده حفظ بهتر ساختار است.

$$SSIM(x,y) = ((2\mu_x\mu_y+C_1)(2\sigma_{xy}+C_2)) / ((\mu_x^2+\mu_y^2+C_1)(\sigma_x^2+\sigma_y^2+C_2))$$

```
psnr_value = psnr_score(pristine_np, restored_np, data_range=1.0)
ssim_value = ssim_score(
    pristine_np, restored_np, data_range=1.0, channel_axis=-1
)
```

۸. نتایج کمی

وضعیت	حداقل موردنیاز	حداقل مجموعه تست	انحراف معیار	میانگین	معیار
قبول	20 dB	7.146526 dB	3.784416	22.743325 dB	PSNR
قبول	0.65	0.340873	0.096168	0.856759	SSIM
هرچه کمتر، بهتر است	-	0.000645	0.012296	0.008259	MSE
هرچه کمتر، بهتر است	-	0.017922	0.033583	0.059174	MAE

جدول ۵ - نتایج کمی مدل روی ۵۰۰ تصویر مجموعه تست

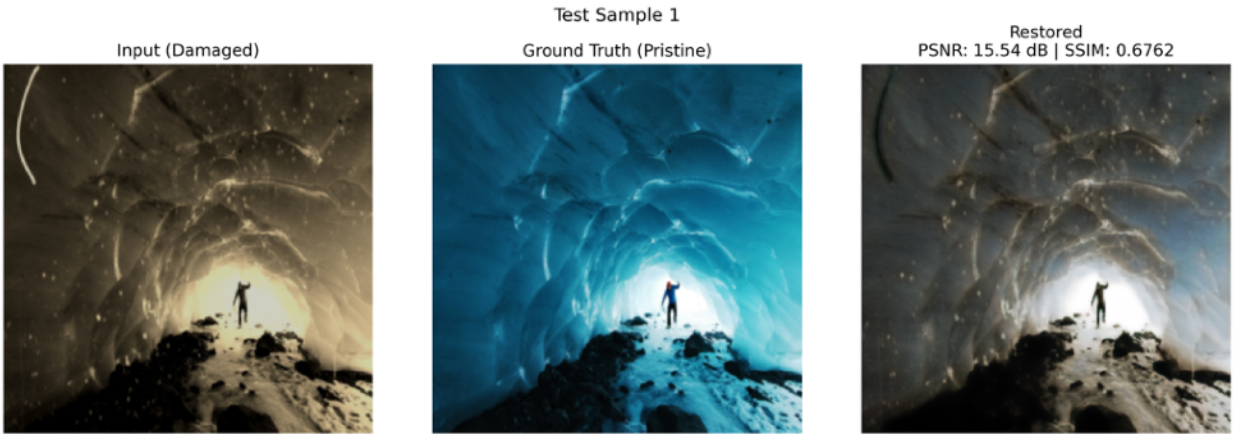
میانگین PSNR برابر ۲۲٫۷۴۳۳ دسی‌بل است و ۲٫۷۴ دسی‌بل از حداقل تعیین‌شده در پروژه بیشتر است. میانگین SSIM برابر ۰٫۸۵۶۸ است که فاصله مناسبی با آستانه ۰٫۶۵ دارد. بنابراین مدل هر دو معیار اجباری پروژه را با موفقیت برآورده کرده است. مقدار SSIM نسبتاً بالا نشان می‌دهد ساختار کلی، مکان اشیا و الگوهای اصلی تصویر به‌خوبی حفظ شده‌اند.

PSNR متوسط رو به خوب است، اما پایین‌تر بودن آن نسبت به SSIM نشان می‌دهد اختلاف‌های رنگ، روشنایی و شدت پیکسل هنوز در برخی تصاویر وجود دارد؛ این برداشت با مشاهده نمونه‌های خروجی نیز سازگار است.

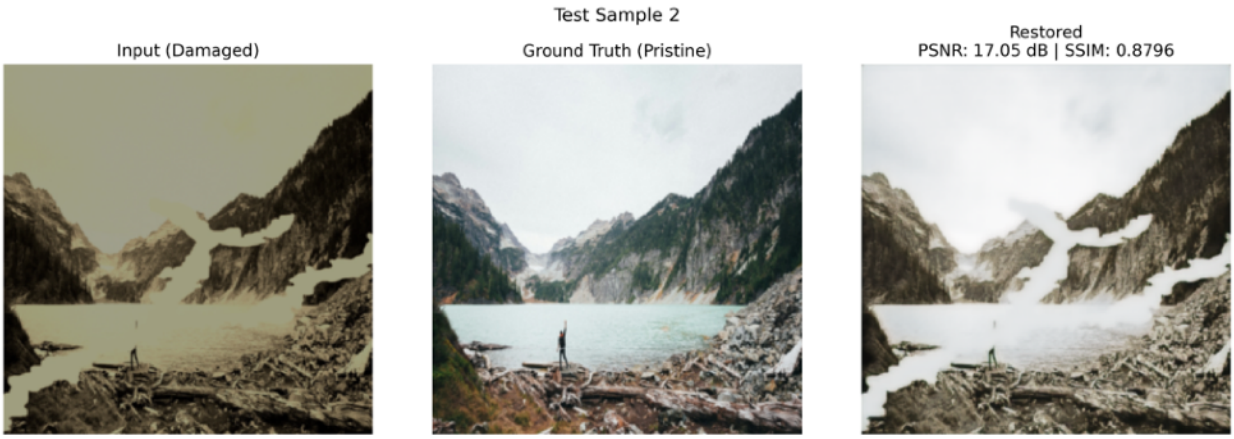
حداقل عملکرد: PSNR ≥ 20 dB و SSIM ≥ 0.65؛ نتایج این مدل به‌ترتیب 22.7433 dB و 0.8568 هستند و هر دو معیار قبول شده‌اند.

۹. نمونه خروجی‌های تصویری

برای ارزیابی کیفی، ۱۰ نمونه از نقاط مختلف مجموعه تست انتخاب شدند. انتخاب نمونه‌ها با فاصله یکنواخت در کل مجموعه تست انجام شده است و فقط به اولین تصاویر محدود نیست. در هر شکل، ستون چپ ورودی آسیب‌دیده، ستون میانی تصویر سالم مرجع و ستون راست خروجی بازسازی‌شده مدل را نشان می‌دهد. مقدار PSNR و SSIM همان نمونه نیز روی خروجی درج شده است.



شکل 4 - نمونه تست 1: PSNR = 15.54 dB و SSIM = 0.6762



شکل 5 - نمونه تست 2: PSNR = 17.05 dB و SSIM = 0.8796



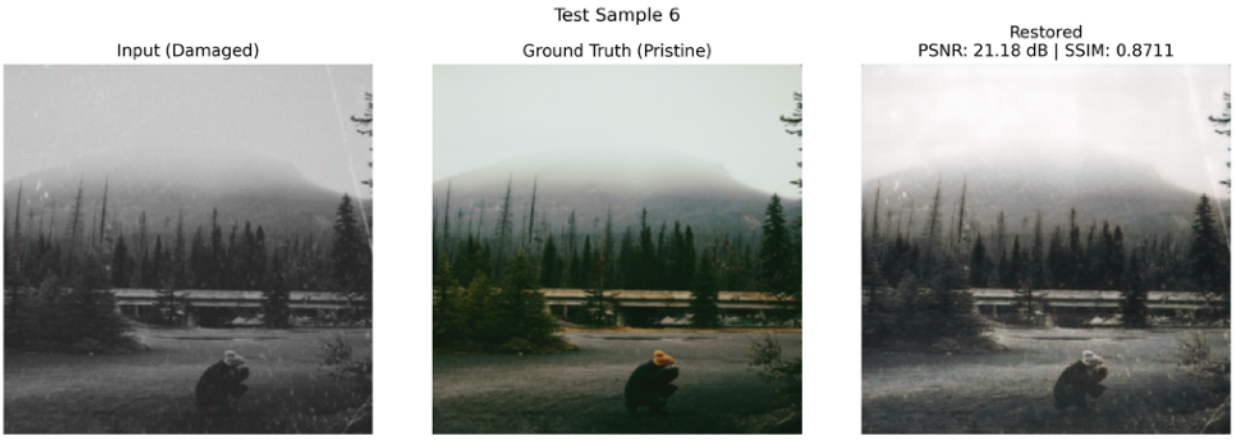
شکل 6 - نمونه تست 3: PSNR = 23.85 dB و SSIM = 0.9693



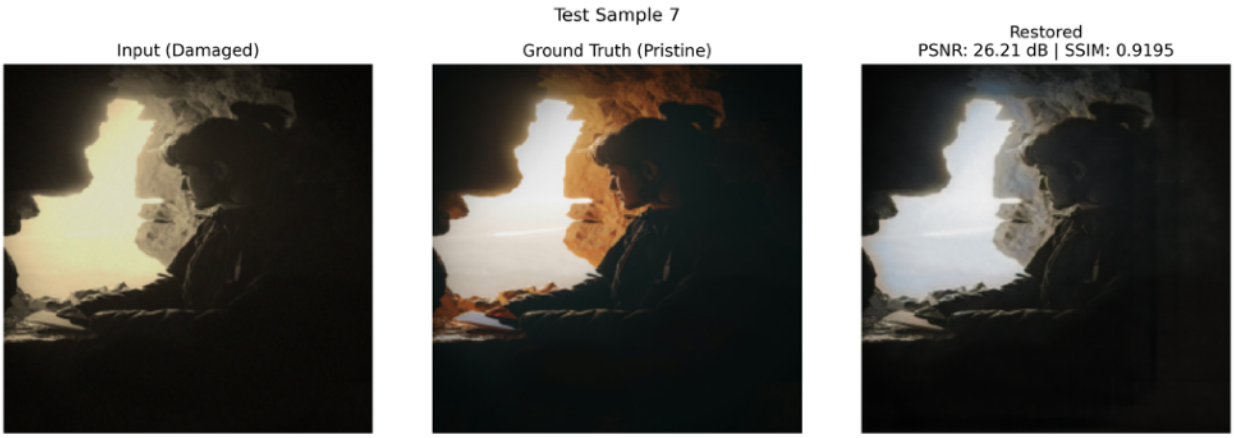
شکل 7 - نمونه تست 4: PSNR = 20.26 dB و SSIM = 0.7648



شکل 8 - نمونه تست 5: PSNR = 24.02 dB و SSIM = 0.9069



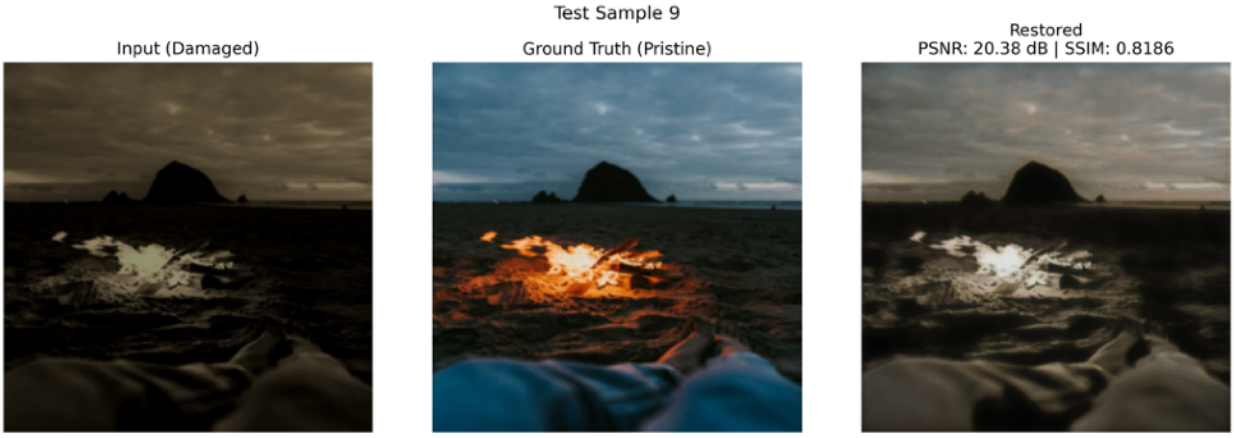
شکل 9 - نمونه تست 6: PSNR = 21.18 dB و SSIM = 0.8711



شکل 10 - نمونه تست 7: PSNR = 26.21 dB و SSIM = 0.9195



شکل 11 - نمونه تست 8: PSNR = 21.21 dB و SSIM = 0.7695



شکل 12 - نمونه تست 9: PSNR = 20.38 dB و SSIM = 0.8186



شکل 13 - نمونه تست 10: PSNR = 23.61 dB و SSIM = 0.7931

۹-۱. تحلیل نمونه‌های انتخابی

نمونه	PSNR (dB)	SSIM	مشاهده و تحلیل کیفی
1	15.54	0.6762	ساختار کلی تونل و سوژه حفظ شده است، اما بازیابی رنگ آبی یخ و حذف کامل آثار تخریب محدود بوده است.
2	17.05	0.8796	ساختار کوه‌ها، دریاچه و پیش‌زمینه به‌خوبی حفظ شده، ولی تفاوت روشنایی و رنگ با تصویر مرجع باعث کاهش PSNR
3	23.85	0.9693	یکی از بهترین نمونه‌ها؛ ساختار، آسمان، سوژه و بافت زمین با شباهت بسیار زیاد بازسازی شده‌اند.

نمونه	PSNR (dB)	SSIM	مشاهده و تحلیل کیفی
4	20.26	0.7648	چیدمان شاخه‌ها و نواحی روشن حفظ شده، اما بازگردانی رنگ سبز و حذف لکه‌ها کامل نیست.
5	24.02	0.9069	جزئیات هندسی ساختمان‌ها و سوژه مرکزی خوب حفظ شده و کیفیت کلی بازسازی مطلوب است.
6	21.18	0.8711	ساختار منظره، خطوط درختان و سوژه پایین تصویر حفظ شده، ولی رنگ‌ها همچنان کم‌رنگ و متمایل به خاکستری‌اند.
7	26.21	0.9195	بهترین PSNR در میان نمونه‌های انتخابی؛ ساختار غار و نیم‌رخ فرد دقیق حفظ شده، هرچند رنگ گرم تصویر مرجع کامل بازنگشته است.
8	21.21	0.7695	بافت پوست جانور و شکل آن بازسازی شده، ولی رنگ محیط و پس‌زمینه سبز به‌طور کامل بازیابی نشده است.
9	20.38	0.8186	ساختار ساحل و آتش حفظ شده، اما شدت رنگ نارنجی آتش و رنگ آبی پس‌زمینه کمتر از مرجع است.
10	23.61	0.7931	سوژه و بازتاب آب حفظ شده‌اند، ولی برخی خطوط و خراش‌های مصنوعی هنوز در خروجی باقی مانده‌اند.

جدول ۶ - تحلیل کمی و کیفی ۱۰ خروجی منتخب

۱۰. تحلیل نتایج

۱۰-۱. نقاط قوت مشاهده‌شده

• حفظ ساختار و هندسه: در اغلب نمونه‌ها محل اشیا، مرزهای اصلی و ترکیب‌بندی تصویر حفظ شده است؛ SSIM میانگین ۰,۸۵۶۸ این موضوع را تأیید می‌کند.

• حفظ جزئیات محلی: بافت ساختمان، تنه و شاخه درختان، خطوط کوه، پوست جانور و مرز سوژه‌ها در بسیاری از نمونه‌ها قابل تشخیص باقی مانده است.

• پایداری در صحنه‌های متنوع: نمونه‌ها شامل منظره طبیعی، فضای شهری، سوژه انسانی و حیوان هستند و مدل در همه آن‌ها خروجی قابل استفاده تولید کرده است.

• عدم تغییر شدید محتوای تصویر: مدل برخلاف برخی مدل‌های مولد، شیء یا ساختار جدید و نامرتبط به تصویر اضافه نکرده و محتوای اصلی را حفظ کرده است.

۱۰-۲. الگوی خطاها و علت تفاوت PSNR و SSIM

در چند نمونه، خروجی از نظر ساختار بسیار شبیه تصویر مرجع است، اما رنگ‌های اصلی کامل بازیابی نشده‌اند. برای مثال در نمونه ۲، SSIM برابر ۰,۸۷۹۶ است ولی PSNR فقط ۱۷,۰۵ دسی‌بل است. این اختلاف نشان می‌دهد شکل کوه، دریاچه و اجزای صحنه حفظ شده‌اند، اما اختلاف رنگ و روشنایی باعث خطای پیکسلی بالا شده است. نمونه‌های ۴، ۶، ۸ و ۹ نیز رفتار مشابهی دارند؛ ساختار مطلوب است ولی خروجی تا حدی خاکستری یا کم‌اشباع باقی می‌ماند.

این رفتار با ماهیت تابع L1 سازگار است. L1 برای کاهش خطای متوسط پیکسل پایدار است، اما در موقعیت‌هایی که بازیابی رنگ چند پاسخ ممکن دارد، مدل ممکن است پاسخ محافظه‌کارانه و نزدیک به میانگین تولید کند. از سوی دیگر، Skip Connectionها جزئیات مکانی را خوب منتقل می‌کنند، ولی ممکن است بخشی از الگوهای خرابی ورودی مانند خطوط سفید و خراش‌ها را نیز به مسیر رمزگشا انتقال دهند؛ این موضوع در نمونه ۱۰ و تا حدی نمونه ۵ دیده می‌شود.

۱۰-۳. بهترین و دشوارترین نمونه‌ها

در میان ۱۰ نمونه انتخابی، نمونه ۷ با PSNR برابر ۲۶,۲۱ دسی‌بل و SSIM برابر ۰,۹۱۹۵ بهترین PSNR را دارد و ساختار غار و نیم‌رخ فرد را بسیار خوب حفظ کرده است. نمونه ۳ با SSIM برابر ۰,۹۶۹۳ بیشترین شباهت ساختاری را در این مجموعه نمونه‌ها دارد. دشوارترین نمونه انتخابی، نمونه ۱ با PSNR برابر ۱۵,۵۴ دسی‌بل است؛ زیرا تفاوت رنگ آبی یخ در تصویر مرجع با رنگ تیره در ورودی زیاد است و مدل نتوانسته است رنگ واقعی را به‌طور کامل بازیابی کند. با این حال SSIM آن ۰,۶۷۶۲ است و نشان می‌دهد ساختار کلی همچنان حفظ شده است.

۱۱. مشکلات و محدودیت‌ها

• زمان و هزینه محاسباتی: U-Net با کانال‌های ۶۴ تا ۱۰۲۴ و ورودی ۲۵۶×۲۵۶ مدل نسبتاً سنگینی است و آموزش روی CPU بسیار کند خواهد بود.

• بازیابی ناقص رنگ: در ورودی‌های خاکستری یا سپیا، خروجی گاهی فقط بخشی از رنگ‌های اصلی را بازمی‌گرداند و کم‌اشباع باقی می‌ماند.

• باقی ماندن برخی خراش‌ها: در آسیب‌های شدید، بخشی از ترک‌ها یا خطوط سفید در خروجی دیده می‌شوند؛ احتمالاً انتقال مستقیم ویژگی‌ها از Skip Connectionها یکی از عوامل است.

• رزولوشن محدود: تغییر اندازه همه تصاویر به ۲۵۶×۲۵۶ زمان آموزش را کاهش می‌دهد، اما جزئیات بسیار ریز تصویر اصلی را حذف می‌کند.

• تفاوت میان آسیب مصنوعی و واقعی: مجموعه‌داده با اعمال تخریب مصنوعی ساخته شده است؛ بنابراین ممکن است عملکرد روی عکس‌های تاریخی واقعی با الگوهای آسیب متفاوت، کمتر باشد.

• وابستگی معیارهای کمی به رنگ و شدت پیکسل: ممکن است تصویر از نظر بصری و ساختاری مناسب باشد، اما به دلیل تفاوت رنگ PSNR پایین‌تری به دست آورد.

۱۲. پیشنهاد برای بهبود

1) استفاده از تابع هزینه ترکیبی مانند L1 + SSIM Loss برای بهینه‌سازی هم‌زمان دقت پیکسلی و شباهت ساختاری.

2) افزودن Perceptual Loss مبتنی بر ویژگی‌های یک شبکه ازپیش‌آموزش‌دیده برای حفظ بهتر بافت و ظاهر ادراکی.

3) استفاده از Attention U-Net یا مکانیزم توجه برای تمرکز بیشتر بر نواحی آسیب‌دیده و کاهش انتقال مستقیم خرابی‌ها در Skip Connectionها.

4) آموزش در رزولوشن ۵۱۲×۵۱۲ یا استفاده از روش patch-based برای حفظ جزئیات ریز، در صورت دسترسی به حافظه GPU کافی.

5) افزایش تنوع داده و اعمال Data Augmentationهای سازگار روی هر دو تصویر ورودی و هدف، مانند برش، چرخش و وارون‌سازی هم‌زمان.

6) افزودن زیان ویژه رنگ یا استفاده از فضای رنگ Lab برای تقویت بازیابی رنگ در کنار حفظ روشنایی و ساختار.

7) استفاده از یک مرحله پالایش مبتنی بر GAN پس از U-Net، در صورتی که هدف افزایش شارپنس و کیفیت ادراکی باشد؛ این کار باید با کنترل دقیق برای جلوگیری از تولید جزئیات غیرواقعی انجام شود.

8) ارزیابی روی تصاویر قدیمی واقعی خارج از مجموعه‌داده و مقایسه با روش‌های پایه برای بررسی تعمیم مدل در شرایط واقعی.

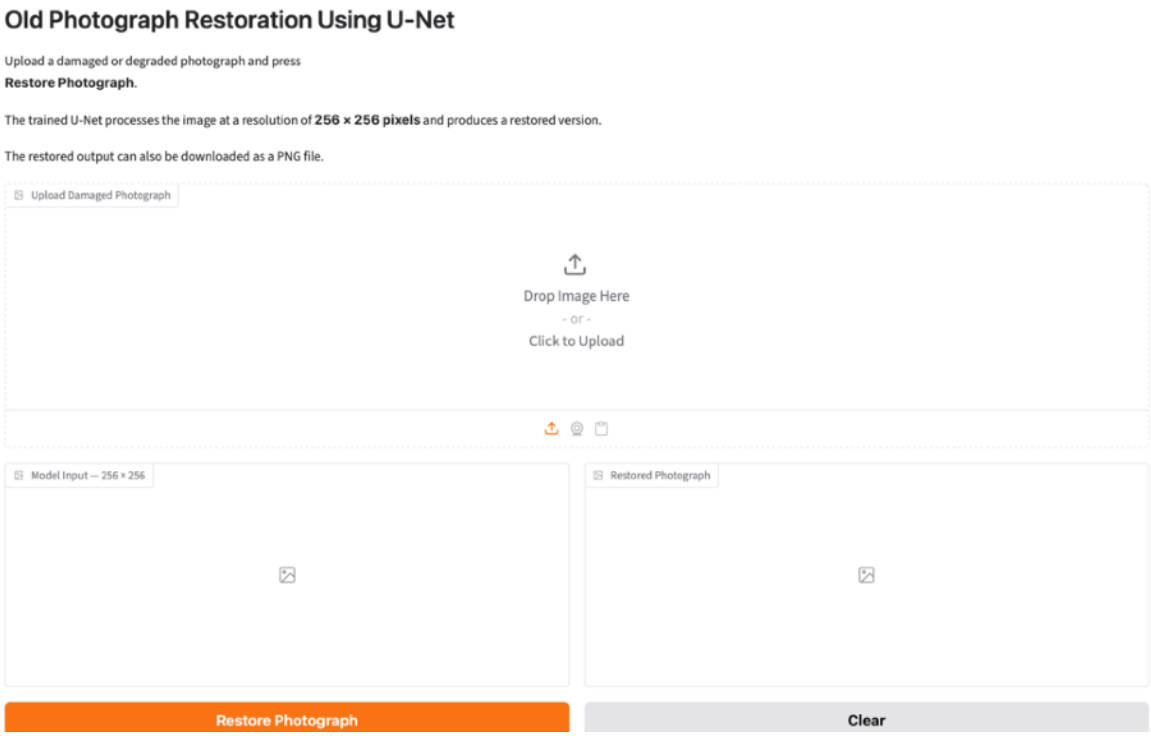
۱۳. بخش امتیازی

پس از عبور مدل از آستانه‌های کمی پروژه، یک رابط کاربری مستقل با Gradio پیاده‌سازی و در Google Colab اجرا شد. کد کامل این بخش در فایل py.bonus_project قرار دارد. رابط به کاربر اجازه می‌دهد تصویر آسیب‌دیده را بارگذاری کند، ورودی واقعی شبکه را ببیند، خروجی بازسازی‌شده را مشاهده کند و فایل PNG نتیجه را دریافت نماید.

۱۳-۱. ساختار کلی رابط و مؤلفه‌های آن

رابط با Blocks.gr ساخته شده و تمام عنوان‌ها، دکمه‌ها و پیام‌های آن به زبان انگلیسی هستند. ورودی تصویر از سه منبع Upload، Webcam و Clipboard پشتیبانی می‌کند. پس از فشردن دکمه Restore Photograph، تابع photo_restore اجرا می‌شود و چهار خروجی شامل پیش نمایش ورودی مدل، تصویر بازسازی‌شده، فایل قابل دریافت و پیام وضعیت تولید می‌گردد.

- Upload Damaged Photograph: دریافت تصویر آسیب‌دیده از فایل، دوربین یا Clipboard.
- Model Input - 256 × 256: نمایش نسخه تغییراندازه‌یافته‌ای که واقعاً به Net-U وارد می‌شود.
- Restored Photograph: نمایش خروجی نهایی مدل.
- Restore Photograph: اجرای پیش پردازش و استنتاج.
- Clear: پاک‌کردن پنل‌های تصویری ورودی و خروجی.
- Download Restored PNG: دریافت خروجی بازسازی‌شده در قالب PNG.
- Processing Status: نمایش موفقیت یا خطای اجرا، اندازه ورودی، دستگاه محاسباتی و اطلاعات checkpoint.



شکل ۱۴ - نمای اولیه رابط کاربری انگلیسی Gradio پیش از بارگذاری تصویر

۱۳-۲. تعریف مدل و بارگذاری checkpoint

برای جلوگیری از ناسازگاری وزن‌ها، همان کلاس های DoubleConv و UNet استفاده‌شده در آموزش، با کانال‌های ۶۴، ۱۲۸، ۲۵۶ و ۵۱۲ در کد رابط نیز تعریف شده‌اند. برنامه فایل pth.restore_unet_best را در چند مسیر متداول Colab و Google Drive جست‌وجو می‌کند. این موضوع باعث می‌شود رابط در صورت جابه‌جایی پوشه خروجی نیز با تغییر حداقلی قابل اجرا باشد.

checkpoint با location_map روی CPU یا GPU بارگذاری می‌شود. اگر فایل شامل دیکشنری کامل آموزش باشد، وزن‌ها از dict_state_model خوانده می‌شوند و شماره بهترین epoch و Validation Loss نیز استخراج می‌گردند. کد همچنین از فایل‌های قدیمی‌تری که فقط dict_state مدل را ذخیره کرده اند پشتیبانی کرده است. پس از بارگذاری وزن‌ها، مدل با ui_model.eval() در حالت ارزیابی قرار گرفته است.

```
checkpoint = torch.load(MODEL_PATH, map_location=DEVICE, weights_only=False)

if isinstance(checkpoint, dict) and "model_state_dict" in checkpoint:
    ui_model.load_state_dict(checkpoint["model_state_dict"])
    best_epoch = checkpoint.get("epoch", "Unknown")
    best_validation_loss = checkpoint.get("best_val_loss", "Unknown")
else:
    ui_model.load_state_dict(checkpoint)

ui_model.eval()
```

۱۳-۳. پیش پردازش تصویر در رابط

پیش پردازش رابط عمدی آن رت با پیش پردازش مرحله آموزش یکسان نگه داشته ایم. ابتدا تصویر به RGB تبدیل می‌شود، سپس به ابعاد ثابت ۲۵۶×۲۵۶ تغییر اندازه می‌یابد و با ToTensor به Tensor سه‌کاناله با مقادیر نرمال‌شده در بازه صفر تا یک تبدیل می‌شود. در ادامه با unsqueeze یک بعد batch افزوده شده و Tensor به دستگاه محاسباتی انتخاب‌شده منتقل می‌گردد. این تطابق میان آموزش و استنتاج از افت عملکرد ناشی از تغییر شیوه آمادهسازی ورودی جلوگیری می‌کند.

```
ui_transform = transforms.Compose([
    transforms.Resize((IMAGE_SIZE, IMAGE_SIZE), antialias=True),
    transforms.ToTensor()
])

uploaded_image = uploaded_image.convert("RGB")
input_tensor = ui_transform(uploaded_image).unsqueeze(0).to(DEVICE)
```

۱۳-۴. استنتاج و ذخیره خروجی

استنتاج درون mode_inference.torch() انجام می‌شود؛ بنابراین گرادیان محاسبه یا ذخیره نمی‌شود و مصرف حافظه کمتر از حالت آموزش است. خروجی مدل پس از حذف بعد batch به CPU منتقل و به بازه صفر تا یک محدود می‌شود. سپس Tensor به تصویر PIL تبدیل شده و علاوه بر نمایش در رابط، با استفاده از NamedTemporaryFile در یک فایل PNG موقت ذخیره می‌گردد تا کاربر بتواند آن را دریافت کند.

```
with torch.inference_mode():
    restored_tensor = ui_model(input_tensor)

restored_tensor = restored_tensor.squeeze(0).detach().float().cpu().clamp(0.0, 1.0)
restored_image = tensor_to_image(restored_tensor)
restored_image.save(output_path, format="PNG")
```

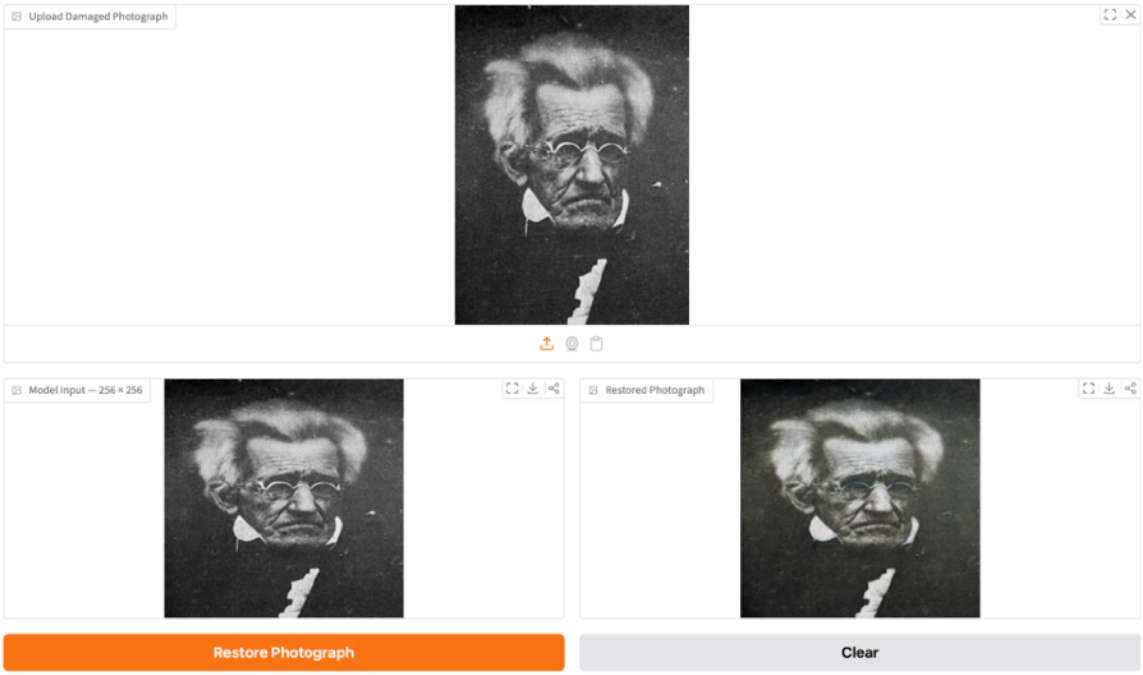
۱۳-۵. اتصال رویدادها و اجرای Gradio

رویداد کلیک Restore Photograph به تابع photo_restore متصل شده است. در کد نهایی رابط با True=inline و True=share اجرا می‌شود؛ بنابراین رابط داخل Colab نمایش داده شده و همزمان یک لینک عمومی موقت Gradio نیز ایجاد می‌گردد. این لینک فقط تا زمانی فعال است که Runtime مربوط به Colab در حال اجرا باشد.

```
restore_button.click(
    fn=restore_photo,
    inputs=[uploaded_image_input],
    outputs=[input_preview_output, restored_image_output,
```

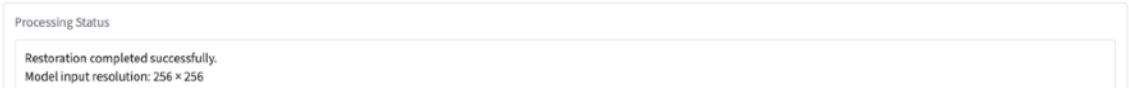
۱۳-۶. نتیجه اجرای رابط روی تصویر خارجی

برای آزمون عملی رابط، یک عکس تاریخی سیاه‌وسفید که بخشی از مجموعه تست پروژه نبود بارگذاری شد. رابط تصویر را بدون نیاز به تغییر کد دریافت کرد، نسخه ۲۵۶×۲۵۶ را به شبکه فرستاد و خروجی بازسازی‌شده را در پنل مقابل نمایش داد. این آزمایش، صحت مسیر کامل بارگذاری، پیش پردازش، اجرای مدل و نمایش نتیجه را تأیید می‌کند. چون تصویر سالم متناظر این عکس در دسترس نیست، برای این نمونه نمی‌توان PSNR یا SSIM محاسبه کرد و خروجی فقط به‌صورت کیفی تفسیر می‌شود.



شکل ۱۵ - اجرای واقعی رابط روی یک عکس تاریخی خارج از مجموعه تست و نمایش ورودی و خروجی مدل

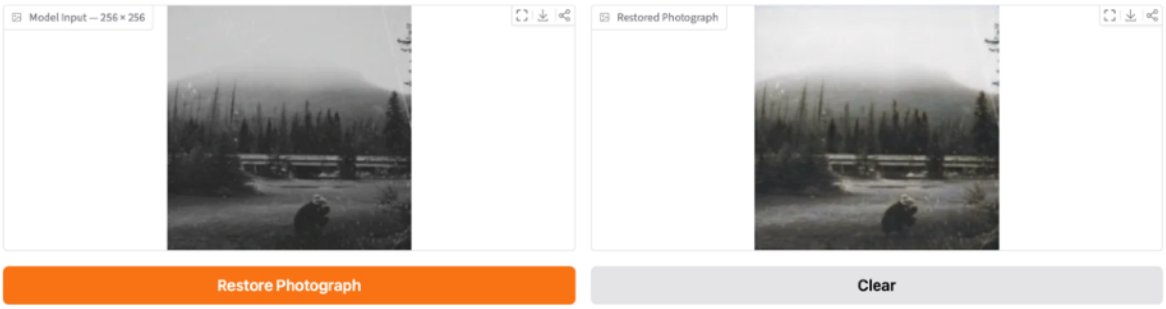
پس از پایان این بخش، پنل Processing Status پیام Restoration completed successfully و اندازه ورودی مدل را نمایش داد. این پیام نشان می‌دهد تابع بدون خطای اجرایی پایان یافته و خروجی قابل دریافت تولید شده است.



شکل ۱۶ - پیام موفقیت پردازش در رابط کاربری

۱۳-۷. نتیجه اجرا روی نمونه‌ای نزدیکتر به داده‌های پروژه

رابط روی یک تصویر آسیب‌دیده دیگر که از نظر نوع تخریب به داده‌های پروژه نزدیکتر بود نیز اجرا شد. خروجی نشان داد که ساختار اصلی منظره حفظ شده و شبکه تغییراتی در روشنایی و ظاهر کلی تصویر ایجاد کرده است. هدف این تصویر، نمایش امکان پردازش ورودی‌های مختلف در همان رابط و بدون بازآموزی مدل است.



شکل ۱۷ - اجرای رابط روی نمونه دوم و نمایش Model Input در کنار Restored Photograph

۱۳-۸. محدودیت‌های رابط کاربری

- اندازه ورودی و خروجی مدل ثابت و برابر ۲۵۶×۲۵۶ است؛ بنابراین تصاویر بزرگتر پیش از استنتاج کوچک می‌شوند.
- برای تصاویر دلخواه بدون Ground Truth، معیارهای PSNR و SSIM قابل محاسبه نیستند.
- کیفیت نتیجه به میزان شباهت تصویر جدید با توزیع داده‌های آموزشی وابسته است.
- فایل خروجی رابط موقت است و باید توسط کاربر دریافت یا در Drive ذخیره شود.
- لینک عمومی Gradio و خود رابط به فعال بودن Runtime محیط Colab وابسته‌اند.
- وجود checkpoint آموزش دیده ضروری است؛ رابط فقط استنتاج انجام می‌دهد و مدل را دوباره آموزش نمی‌دهد.

۱۳-۹. جمع‌بندی این بخش

رابط انگلیسی Gradio تصویر را از کاربر دریافت می‌کند، همان پیش پردازش مرحله آموزش را اعمال می‌نماید، بهترین checkpoint مدل را بارگذاری می‌کند، استنتاج را بدون محاسبه گرادیان انجام می‌دهد و خروجی را هم برای مشاهده و هم برای دریافت به‌صورت PNG ارائه می‌کند.

۱۴. نتیجه‌گیری

در این پروژه یک مدل U-Net برای بازسازی تصاویر آسیب‌دیده به صورت یادگیری نظارت‌شده پیاده‌سازی شد. تمام مراحل خواسته‌شده شامل بارگذاری جفت داده‌ها، پیش‌پردازش، تقسیم آموزش/اعتبارسنجی/تست، ساخت DataLoader، تعریف مدل، آموزش، ذخیره و رسم loss، ارزیابی کمی و نمایش خروجی‌های تصویری انجام شد. روند کاهش Train و Validation Loss نشان داد مدل به شکل پایدار یاد گرفته و نشانه واضحی از بیش‌برازش شدید مشاهده نشد.

مدل روی ۵۰۰ تصویر تست به میانگین PSNR برابر ۲۲٫۷۴۳۳ دسی‌بل و SSIM برابر ۰٫۸۵۶۸ رسید؛ بنابراین هر دو آستانه الزامی پروژه را پشت سر گذاشت. نتایج کیفی نشان دادند Net-U در حفظ ساختار، لبه‌ها و محتوای اصلی تصویر موفق است. محدودیت اصلی در برخی نمونه‌ها بازیابی ناقص رنگ و باقی ماندن بخشی از خراش های شدید بود. در مجموع، مدل ارائه‌شده یک راه‌حل پایدار و قابل قبول برای مسئله بازسازی تصاویر آسیب‌دیده است و با استفاده از زیان‌های ترکیبی، مکانیزم توجه، رزولوشن بالاتر و داده‌های واقعی می‌توان کیفیت آن را بیشتر بهبود داد. همچنین در بخش امتیازی، رابط کاربری Gradio به‌صورت واقعی اجرا شد و امکان بارگذاری تصویر، نمایش خروجی بازسازی‌شده و دریافت فایل PNG فراهم شده است.